

# Monitoria MAT1202 - Álgebra Linear 2

## Apostila Notas de Aula

Matheus Nogueira

### Resumo

Este documento consiste nas notas de aula da monitoria de MAT1202. Este material foi produzido com base em minhas anotações do curso de Álgebra Linear 2 do semestre 20.2 e do livro *Álgebra Linear e suas aplicações*, de *Gilbert Strang*. Qualquer dúvida, favor entrar em contato *matnogueira@gmail.com*

## Sumário

<b>1</b>	<b>Sistemas Lineares e Eliminação Gaussiana</b>	<b>3</b>
1.1	Sistemas Lineares e Notação Matricial . . . . .	3
1.2	Solução de um Sistema Linear . . . . .	3
1.2.1	Operações Elementares . . . . .	4
1.2.2	Matrizes das operações elementares . . . . .	4
1.3	Exemplo . . . . .	5
1.4	Conclusão . . . . .	6
<b>2</b>	<b>Fatoração <math>A=LU</math></b>	<b>7</b>
2.1	Sem permutação de linhas . . . . .	7
2.1.1	Exemplo . . . . .	8
2.2	Fatoração $PA=LU$ (com permutação de linhas) . . . . .	9
2.2.1	Exemplo . . . . .	9
2.3	Conclusão . . . . .	10
<b>3</b>	<b>Espaços Fundamentais de uma Matriz</b>	<b>10</b>
3.1	Definições: . . . . .	10
3.1.1	Espaço Coluna - $Im(A)$ . . . . .	10
3.1.2	Espaço Nulo - $N(A)$ . . . . .	10
3.1.3	Espaço Linha - $Im(A^T)$ . . . . .	11
3.1.4	Espaço Nulo da Transposta- $N(A^T)$ . . . . .	11
3.2	Exemplo: . . . . .	11
3.3	Conclusão . . . . .	13
<b>4</b>	<b>Ortogonalidade</b>	<b>13</b>
4.1	Produto Interno . . . . .	13
4.2	Norma . . . . .	13
4.3	Ortogonalidade e Espaços Vetoriais . . . . .	14
4.3.1	Espaços Ortogonais . . . . .	14

4.3.2	Complemento Ortogonal . . . . .	14
4.4	Conclusão . . . . .	14
<b>5</b>	<b>Projeções Ortogonais</b>	<b>14</b>
5.1	Conceitos importantes . . . . .	14
5.2	Projeção ortogonal sobre um vetor . . . . .	15
5.2.1	Matriz de Projeção sobre o vetor $u$ . . . . .	16
5.2.2	Exemplo: . . . . .	16
5.2.3	Propriedades: . . . . .	16
5.3	Projeção Ortogonal sobre um subespaço qualquer . . . . .	16
5.4	Conclusão . . . . .	17
<b>6</b>	<b>Mínimos Quadrados</b>	<b>17</b>
6.1	Motivação . . . . .	17
6.2	Relembrando Projeções Ortogonais . . . . .	18
6.3	Mínimos Quadrados . . . . .	18
6.3.1	Exemplo: . . . . .	18
6.4	Conclusão . . . . .	19
<b>7</b>	<b>Matrizes Ortogonais, Ortogonalização de Grand-Schmidt e Fatoração QR</b>	<b>19</b>
7.1	Matrizes Ortogonais . . . . .	19
7.1.1	Propriedades . . . . .	19
7.2	Ortogonalização de Grand Schmidt . . . . .	20
7.3	Fatoração QR . . . . .	20
7.4	Conclusão . . . . .	21

# 1 Sistemas Lineares e Eliminação Gaussiana

## 1.1 Sistemas Lineares e Notação Matricial

Nosso foco é estudar sistemas de equações da forma  $Ax = b$ , onde  $A$  é a matriz com os termos que acompanham as variáveis (incógnitas),  $x$  é o vetor coluna com as incógnitas e  $b$  é o vetor coluna com os termos independentes.

**Exemplo:** Seja o seguinte sistema de equações...

$$\begin{aligned}x + 2y + 3 &= 2 \\ -x + y - z &= -3 \\ 2x + y - z &= 0\end{aligned}$$

Escrevê-lo em forma matricial é definir as seguinte matriz e vetores:

$$A = \begin{bmatrix} 1 & 2 & 3 \\ -1 & 1 & -1 \\ 2 & 1 & -1 \end{bmatrix}, x = \begin{bmatrix} x \\ y \\ z \end{bmatrix} \text{ e } b = \begin{bmatrix} 2 \\ -3 \\ 0 \end{bmatrix}$$

Não é difícil perceber que a multiplicação representada por  $Ax$  resulta exatamente no sistema linear inicial.

## 1.2 Solução de um Sistema Linear

Nossa estratégia para calcular a solução de um sistema de equações lineares será a **Eliminação Gaussiana**.

Este método consiste em realizar operações na matriz do sistema  $Ax = b$ , chamadas *operações elementares*, para chegar a um *sistema triangular*. Ao ser obtido este sistema, basta realizar uma série de substituições retroativas para chegar à solução.

**Definição:** Matrizes Triangulares

Uma matriz é triangular - superior ou inferior - se todas as entradas abaixo ou acima, respectivamente, da diagonal principal são nulas. A matriz  $A$  abaixo é triangular superior, enquanto que  $B$  é triangular inferior.

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 1 & -1 \\ 0 & 0 & -1 \end{bmatrix}, B = \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 2 & 1 & -1 \end{bmatrix}$$

São 3 os possíveis tipos de solução de um sistema linear:

1. Exatamente 1 solução
2. Infinitas Soluções
3. Não há solução

**Observação:** lembrem-se que, para verificar qual das opções acima é a o caso da matriz a ser estudada, podemos olhar para o *determinante* da matriz. Se seu valor for zero, o sistema possui infinitas soluções ou nenhuma solução. Se for diferente de zero, uma solução.

### 1.2.1 Operações Elementares

**Definição:** dado um sistema linear  $Ax = b$ , são 3 as operações elementares que não alteram a solução do sistema.

1. Permutação de linhas ( $L_i \leftrightarrow L_j$ )
2. Multiplicação de linha por escalar ( $L_i \rightarrow L_i \cdot k, k \neq 0$ )
3. Somar um múltiplo de uma linha a outra linha ( $L_i \rightarrow L_i + k \cdot L_j$ )

### 1.2.2 Matrizes das operações elementares

Veremos que cada uma das 3 operações elementares descritas pode ser representada por meio de matrizes da seguinte forma:

Se queremos realizar a operação elementar  $e$  sobre a matriz  $A$ , devemos realizar a multiplicação  $E \cdot A$ , onde  $E$  é a matriz que representa a operação elementar  $e$ .

Vejamos as como montar as matrizes para as mesmas 3 operações já apresentadas. Por facilidade, usaremos matrizes  $3 \times 3$ , pois o raciocínio para outras dimensões é o mesmo. Começamos sempre com a matriz identidade e:

1. Permutação de linhas ( $L_i \leftrightarrow L_j$ ):  
basta permutar as linhas da matriz identidade de acordo com as linhas a serem permutadas na matriz  $A$
2. Multiplicação de linha por escalar ( $L_i \rightarrow L_i \cdot k, k \neq 0$ ):  
multiplicamos a linha correspondente da matriz identidade pelo escalar em questão.
3. Somar um múltiplo de uma linha a outra linha ( $L_i \rightarrow L_i + k \cdot L_j$ ):  
colocamos na entrada  $i, j$  da matriz identidade o valor de  $k$  com o devido sinal.

$$L_2 \leftrightarrow L_3 \implies \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \leftrightarrow \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} = E \quad (1)$$

$$L_2 \rightarrow L_2 \cdot k \implies \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \leftrightarrow \begin{bmatrix} 1 & 0 & 0 \\ 0 & k \cdot 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = E \quad (2)$$

$$L_3 \rightarrow L_3 - 2 \cdot L_1 \implies \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \leftrightarrow \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ -2 & 0 & 1 \end{bmatrix} = E \quad (3)$$

Ao final da *Eliminação Gaussiana*, depois de serem realizadas todas as devidas *operações elementares*, a matriz obtida estará na forma **escalonada**, isto é:

1. Se existem linhas nulas elas devem ser as últimas da matriz.
2. Em quaisquer duas linhas sucessivas não nulas, o pivô (primeiro elemento não nulo) da linha inferior deve estar mais à direita que o da linha superior.
3. Abaixo do pivô todas as entradas são nulas.

### 1.3 Exemplo

Calculemos a solução do seguinte sistema, mostrando as matrizes das operações elementares.

$$\begin{aligned} 2x + y + z &= 5 \\ 4x - 6y &= 2 \\ -2x + 7y + 2z &= 9 \end{aligned}$$

Em forma matricial o sistema é:

$$\begin{bmatrix} 2 & 1 & 1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 5 \\ -2 \\ 9 \end{bmatrix}$$

Seja a matriz aumentada a ser escalonada a seguir:

$$\begin{bmatrix} 2 & 1 & 1 & 5 \\ 4 & -6 & 0 & -2 \\ -2 & 7 & 2 & 9 \end{bmatrix}$$

Começemos as operações elementares para chegar à matriz escalonada. A cada operação, indicaremos a matriz  $E$  correspondente.

$$L_2 \rightarrow L_2 - 2L_1 \text{ sendo } E_1 = \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Nosso sistema fica...

$$\begin{bmatrix} 2 & 1 & 1 & 5 \\ 0 & -8 & -2 & -12 \\ -2 & 7 & 2 & 9 \end{bmatrix}$$

$$L_3 \rightarrow L_3 + L_1 \text{ sendo } E_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

Nosso sistema fica...

$$\begin{bmatrix} 2 & 1 & 1 & 5 \\ 0 & -8 & -2 & -12 \\ 0 & 8 & 3 & 14 \end{bmatrix}$$

$$L_3 \rightarrow L_3 + L_2 \text{ sendo } E_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}$$

Nosso sistema fica...

$$\begin{bmatrix} 2 & 1 & 1 & 5 \\ 0 & -8 & -2 & -12 \\ 0 & 0 & 1 & 2 \end{bmatrix}$$

Chegamos à matriz escalonada. Agora basta realizar algumas substituições retroativas para calcularmos a solução.

Lendo e substituindo o sistema de baixo para cima temos:

$$\begin{aligned} z &= 2 \\ -8y - 2(2) &= -12 \rightarrow y = 1 \\ 2x + 1 + 2 &= 5 \rightarrow x = 1 \end{aligned}$$

Note que chegamos a uma solução única, o que faz sentido pois  $\det(A) = -16 \neq 0$

Utilizando as matrizes das operações elementares, chegaríamos na mesma matriz escalonada:

$E_3 \cdot E_2 \cdot E_1 \cdot A$ , onde  $A$  é a matriz aumentada

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} 2 & 1 & 1 & 5 \\ 4 & -6 & 0 & -2 \\ -2 & 7 & 2 & 9 \end{bmatrix} = \begin{bmatrix} 2 & 1 & 1 & 5 \\ 0 & -8 & -2 & -12 \\ 0 & 0 & 1 & 2 \end{bmatrix}$$

## 1.4 Conclusão

Com este material sabemos como encontrar a solução de um sistema linear utilizando a Eliminação Gaussiana e as operações Elementares, com suas respectivas matrizes. O próximo assunto a ser abordado será **Fatoração LU**.

## 2 Fatoração $A=LU$

### 2.1 Sem permutação de linhas

No capítulo anterior vimos, ou relembramos, como resolver um sistema linear utilizando o processo da Eliminação Gaussiana por meio, principalmente, de operações elementares e suas matrizes. Neste capítulo continuaremos estudando sistemas lineares do tipo  $Ax = b$  e apresentaremos uma maneira de fatorar a matriz  $A$ , escrevendo-a como  $A = LU$ .

Dito isso, já podemos definir a matriz  $A$  como a matriz de coeficientes do nosso sistema linear, ou seja, exatamente a mesma matriz  $A$  do capítulo anterior. Nosso sistema linear é:

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} b_{11} \\ b_{21} \\ b_{31} \end{bmatrix} \text{ logo, } A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

A matriz  $U$  é a matriz triangular superior que aparece ao final do processo de escalonamento da matriz  $A$ , obtida por meio das operações elementares. Você deve se lembrar que, em nossa aula 2 de *MATLAB*, aprendemos a função `[ , U] = lu(A)`, sendo  $U$  o nome dado à variável que guarda o output da função `lu()`, isto é, a matriz escalonada resultante da eliminação gaussiana. Com  $U$  em mãos, tudo que nos restava fazer era uma substituição retroativa para descobrir a solução do sistema.

A última matriz que falta ser descoberta é  $L$ . Para isso, precisamos lembrar das matrizes  $E_i$  que representam as operações elementares. Se nos recordarmos, para escalonar  $A$  até  $U$  fazíamos:

$$U = E_n \cdot E_{n-1} \cdot \dots \cdot E_2 \cdot E_1 \cdot A$$

sendo  $n$  o número de operações elementares a serem feitas.

Chamemos de  $E$  a matriz resultante de todas as multiplicações de  $E_i$ . Podemos reescrever a equação acima como  $U = E \cdot A$ . Queremos chegar na faturação  $A = LU$ , logo, não é difícil perceber que basta multiplicar ambos os lados de  $U = E \cdot A$  por  $E^{-1}$  à esquerda que obteremos algo similar à fatoração desejada.

$$E^{-1}U = E^{-1}E \cdot A \rightarrow E^{-1} \cdot U = A$$

De fato, a matriz  $L$  da fatoração  $A = LU$  é, justamente, a multiplicação de todas as inversas das matrizes elementares utilizada. Sendo assim, definimos

$$L = E_1^{-1} \cdot E_2^{-1} \cdot \dots \cdot E_n^{-1}$$

Convença-se de que  $L$  está corretamente definida!

O único empecilho para esta definição é garantir que todas as matrizes elementares são inversíveis. Para isso, seus determinantes devem ser diferentes de 0. Como estamos estudando, nesta seção, apenas o caso sem trocas de linha, é trivial notar que todas as matrizes  $E_i$  possuem 1 em sua diagonal principal e são triangulares inferiores. Sendo

assim, seus determinantes são sempre 1. Convença-se deste fato.

Agora podemos apresentar a versão completa da função do *MATLAB*,  $[L, U] = lu(A)$ . Esta função retorna, não somente a matriz escalonada  $U$ , como a matriz  $L$ , o que faz todo o sentido dado o nome da função... A análise da matriz  $L$  é importante para ver se houve trocas de linha na execução interna do algoritmo da função.

Com todas estas definições em mãos, podemos partir para um exemplo.

### 2.1.1 Exemplo

Dada a seguinte matriz  $A$ , calculemos cada uma das matrizes envolvidas na fatoraçoão  $A = LU$  e mostremos que essa igualdade vale.

$$A = \begin{bmatrix} 1 & 1 & 1 \\ 2 & 3 & 5 \\ 4 & 6 & 8 \end{bmatrix}$$

Realizando seu escalonamento, chegamos às seguintes matrizes elementares:

$$E_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ -4 & 0 & 1 \end{bmatrix}; E_2 = \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}; E_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -2 & 1 \end{bmatrix}$$

Podemos verificar (deixo por conta de você, caro aluno) que:

$$E_3 \cdot E_2 \cdot E_1 \cdot A = U \text{ onde, } U = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 3 \\ 0 & 0 & -2 \end{bmatrix}$$

Note que  $U$  é uma matriz triangular superior assim como prevê a teoria! Calculemos agora a matriz  $L$ .

$$L = E_1^{-1} \cdot E_2^{-1} \cdot E_3^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 4 & 2 & 1 \end{bmatrix} \quad (4)$$

Como previsto, a matriz  $L$  é triangular inferior com todas as entradas da diagonal principal igual a 1.

**Dica:** para inverter uma matriz elementar basta trocar o sinal da entrada não nula fora da diagonal principal.

Podemos, por fim, verificar que:

$$L \cdot U = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 4 & 2 & 1 \end{bmatrix} \cdot \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 3 \\ 0 & 0 & -2 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 \\ 2 & 3 & 5 \\ 4 & 6 & 8 \end{bmatrix} = A$$



## 2.2 Fatoração PA=LU (com permutação de linhas)

Caso seja necessário realizar alguma permutação de linhas a fim de garantir que  $U$  será uma matriz escalonada, precisamos corrigir a matriz  $A$ , introduzindo as permutações necessárias para, então, realizar a fatoração  $LU$ . Uma vez detectadas as permutações realizadas, podemos carregar essa informação em uma matriz  $P$  e multiplicá-la por  $A$  de modo que

$$PA = LU$$

Vejamos um exemplo.

### 2.2.1 Exemplo

Dada a seguinte matriz  $A$ , calculemos cada uma das matrizes envolvidas na fatoração  $A = LU$ , mostremos que serão necessárias permutações, montemos a matriz  $P$  e verifiquemos a validade da igualdade  $PA = LU$ .

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 5 \\ 1 & 3 & 4 \end{bmatrix}$$

Para simplificar as contas, usemos a função do *MATLAB*  $[L, U] = lu(A)$ . O retorno desta função é:

$$L = \begin{bmatrix} 0.5 & 0 & 1 \\ 1 & 0 & 0 \\ 0.5 & 1 & 0 \end{bmatrix}; U = \begin{bmatrix} 2 & 4 & 5 \\ 0 & 1 & 1.5 \\ 0 & 0 & 0.5 \end{bmatrix}$$

A matriz  $L$ , neste caso, não é triangular inferior, o que indica que o algoritmo interno da função realizou permutações na matriz  $A$ . Precisamos, então, montar a matriz  $P$  de permutações. Podemos começar trocando as linhas 2 e 3. Para isso, chamemos de  $P_1$  a seguinte matriz de modo que...

$$P_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} \text{ de modo que } P_1 \cdot L = \begin{bmatrix} 0.5 & 0 & 1 \\ 0.5 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix}$$

Agora definimos  $P_2$  a partir da troca das linhas 1 e 3.

$$P_2 = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix} \text{ de modo que } P_2 \cdot P_1 \cdot L = \begin{bmatrix} 1 & 0 & 0 \\ 0.5 & 1 & 0 \\ 0.5 & 0 & 1 \end{bmatrix}$$

Definimos, então,  $P = P_2 \cdot P_1$ . O valor da matriz  $P$  está exibido logo abaixo.

Agora a matriz  $L$  possui as características necessárias segundo a teoria, isto é, ser triangular inferior e possuir todas as entradas da diagonal principal igual a 1.

Podemos, finalmente, verificar que:

$$PA = LU \Leftrightarrow \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 5 \\ 1 & 3 & 4 \end{bmatrix} = \begin{bmatrix} 0.5 & 0 & 1 \\ 1 & 0 & 0 \\ 0.5 & 1 & 0 \end{bmatrix} \cdot \begin{bmatrix} 2 & 4 & 5 \\ 0 & 1 & 1.5 \\ 0 & 0 & 0.5 \end{bmatrix}$$

## 2.3 Conclusão

Neste capítulo foram apresentados os conceitos de fatoraçaõ  $A = LU$  em seu caso sem permutação de linhas e  $PA = LU$  quando são necessárias essas permutações. Este é um algoritmo importante para a compreensão dos métodos de resolução de sistemas lineares e seu entendimento desmistifica o funcionamento da função  $lu()$  utilizada no *MATLAB*.

## 3 Espaços Fundamentais de uma Matriz

### 3.1 Definições:

Estudaremos os 4 subespaços fundamentais de uma matriz. Para todo este estudo, considere  $A$  uma matriz  $m \times n$ . São eles:

1. Espaço Coluna, ou Imagem
2. Espaço Linha
3. Espaço Nulo, ou Núcleo
4. Espaço Nulo da transposta

#### 3.1.1 Espaço Coluna - $Im(A)$

O espaço coluna, ou imagem de uma matriz  $A$  é o subespaço vetorial gerado pelas colunas da matriz  $A$ .

**Def:**

$$Im(A) = \{v \in R^m \text{ tal que } A \cdot u = v \text{ para algum } u \in R^n\}$$

É importante lembrar de alguns conceitos como *Espaços e Subespaços Vetoriais* e *Independência Linear*, uma vez que nada garante que as  $m$  colunas sejam *LI* e gerem um espaço de dimensão  $m$ .

**Base para  $Im(A)$ :** podemos fazer uma Eliminação Gaussiana de  $A$  e observar quais colunas da matriz  $U$  resultante deste processo possuem pivôs. Se as colunas  $c_i$  de  $U$  possuem pivô, então as colunas  $c_i$  de  $A$  serão base da *Imagem* de  $A$ . Consegue perceber o por quê?

**Observação Importante:**  $Im(A) \neq Im(U)$

**Posto** de uma matriz  $A$  é a dimensão da *Imagem* dessa matriz  $A \rightarrow posto(A) = dim(Im(A))$

#### 3.1.2 Espaço Nulo - $N(A)$

O espaço nulo de  $A$  é o espaço vetorial gerado pelos vetores  $x$  tal que  $A \cdot x = 0$ .

**Def:**

$$N(A) = \{x \in R^n \text{ tal que } A \cdot x = 0\}$$

### 3.1.3 Espaço Linha - $Im(A^T)$

O espaço linha de  $A$  é o espaço vetorial gerado pelos vetores linha de  $A$ . De modo análogo, é o *espaço coluna da matriz transposta* de  $A$ .

**Def:**

$$Im(A^T) = \{v \in R^m \text{ tal que } A \cdot u = v \text{ para algum } u \in R^n\}$$

Outra maneira de encontrar o espaço linha de  $A$  é, novamente, por meio da Eliminação Gaussiana. Note que, se  $U$  for a matriz escalonada da Eliminação Gaussiana, então o espaço linha de  $U$  é igual ao espaço linha de  $A$ . Isso quer dizer que uma base de  $Im(U^T)$  é também base de  $Im(A^T)$ .

### 3.1.4 Espaço Nulo da Transposta- $N(A^T)$

O espaço nulo da transposta de  $A$  é o espaço vetorial gerado pelos vetores  $x$  tal que  $A^T \cdot x = 0$ .

**Def:**

$$N(A^T) = \{x \in R^m \text{ tal que } A^T \cdot x = 0\}$$

## 3.2 Exemplo:

Encontre os 4 espaços fundamentais da matriz abaixo.

$$A = \begin{bmatrix} 1 & 1 & 1 \\ 2 & 2 & 2 \\ 3 & 3 & 3 \end{bmatrix}$$

Para encontrar o espaço coluna de  $A$ , vamos escalonar esta matriz. Podemos usar o comando já aprendido  $[U] = lu(A)$ , que nos retorna:

$$U = \begin{bmatrix} 3 & 3 & 3 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

Já podemos perceber a existência de apenas 1 pivô, logo **posto(A)=dim(Im(A))=1**. Com além disso, como o pivô está na primeira coluna de  $U$ , a base da imagem de  $A$  será formada pela primeira coluna de  $A$ . Também podemos usar a função `colspace(sym((A)))` do MATLAB.

$$\beta_{Im(A)} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$$

Para o núcleo de  $A$  devemos resolver o sistema linear  $A \cdot x = 0$  e os vetores  $x$  que satisfizerem esta igualdade serão nosso núcleo. Analogamente, e para facilitar nossa vida,

podemos usar o comando  $B = \text{null}(\text{sym}(A))$ , que retorna:

$$B = \begin{pmatrix} -1 & -1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}$$

Podemos confirmar esta resposta multiplicando  $A * B$  e verificando que esta conta dá **zero**.

**Base:** para verificar que estes vetores nas colunas de  $B$  são base do núcleo, devemos verificar que eles são  $LI$ . Uma vez confirmado, temos que:

$$\beta_{N(A)} = \left\{ \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix} \right\}$$

**Observação:** note que  $\dim(N(A)) = 2$ . Isso faz sentido pois, lembrando de Álgebra 1,  $\dim(\text{Im}(A)) + \dim(N(A)) = n$ .

Para calcularmos o espaço linha, temos duas opções. Primeiro, transpor a matriz  $A$  e calcular a imagem desta nova matriz da maneira já explicada. Por exemplo:  $\text{colspace}(\text{sym}(\text{transpose}(A)))$ . Outra maneira é realizar a fatoração  $LU$  e olhar para as linhas de  $U$ , uma vez que  $\text{Im}(U^T) = \text{Im}(A^T)$ . Como já temos o resultado da função  $\text{lu}(A)$ , podemos notar que a primeira linha de  $U$  é base do espaço linha de  $U$ . Logo,

$$\beta_{\text{Im}(A^T)} = \begin{pmatrix} 3 \\ 3 \\ 3 \end{pmatrix}$$

Finalmente, para o espaço nulo da transposta, podemos utilizar um processo similar ao cálculo do espaço nulo. Será que  $\text{null}(\text{sym}(\text{transpose}(A)))$ , que retorna:

$$\begin{pmatrix} -2 & -3 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}$$

Verificamos se estes vetores são, de fato, a base do núcleo da transposta ao verificar que eles satisfazem  $\text{transpose}(A) \cdot \text{null}(\text{sym}(\text{transpose}(A))) = 0$  e que eles são  $LI$ . Por fim, temos

$$\beta_{N(A)} = \left\{ \begin{pmatrix} -2 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} -3 \\ 0 \\ 1 \end{pmatrix} \right\}$$

### 3.3 Conclusão

Neste capítulo foram apresentados os 4 espaços fundamentais de uma matriz qualquer, bem como os procedimentos necessários para calcular estes subespaços vetoriais. Na próxima aula veremos relações de ortogonalidade entre estes subespaços.

## 4 Ortogonalidade

### 4.1 Produto Interno

O conceito de produto interno já é comum a nós. Sendo assim, vamos apenas defini-lo brevemente:

**DEF:** o produto interno entre dois vetores  $u$  e  $v$ , sendo  $u, v \in R^n$ , representado por  $u \cdot v$  ou  $\langle u, v \rangle$ , é definido por

$$\sum_{k=1}^n x_k y_k = x_1 y_1 + x_2 y_2 + \dots + x_n y_n$$

Algumas propriedades importantes do produto interno são:

1. O produto interno é linear para qualquer argumento  $\rightarrow \langle ku, v \rangle = k\langle u, v \rangle, k \in R$  e  $\langle u + w, v \rangle = \langle u, v \rangle + \langle w, v \rangle, w \in R^n$
2.  $\langle u, u \rangle \geq 0$
3.  $\langle u, v \rangle = \langle v, u \rangle$

Nós utilizamos o conceito de produto interno para definir *ortogonalidade* da seguinte maneira.

**DEF:** dois vetores  $u$  e  $v$  são ditos **ortogonais** se e somente se  $\langle u, v \rangle = 0$

### 4.2 Norma

Podemos pensar na norma de um vetor  $u \in R^n$  como o seu "tamanho" ou "comprimento". Para calcular a norma de um vetor, representada por  $\|u\|$  sabemos que vale:

$$\|u\| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

Note, portanto, que podemos expressar a norma de um vetor utilizando o produto interno!

$$\|u\| = \sqrt{\langle u, u \rangle}$$

**DEF:** Normalização de um vetor

Chamamos de normalização de um vetor o processo de dividi-lo pela sua norma com o intuito do vetor resultante possuir norma igual a 1.

$$\left\| \frac{u}{\|u\|} \right\| = 1$$

**DEF:** dois vetores  $u$  e  $v$  são ditos **ortonormais** se e somente se  $\langle u, v \rangle = 0$  e  $\|u\| = \|v\| = 1$

### 4.3 Ortogonalidade e Espaços Vetoriais

#### 4.3.1 Espaços Ortogonais

**DEF:** Dizer que  $V$  e  $W$  são dois espaços vetoriais ortogonais, ou seja  $V \perp W$  é

$$V \perp W \iff \langle v, w \rangle = 0, \forall v \in V, \forall w \in W$$

A discussão de espaços ortogonais é interessante para avaliarmos os espaços fundamentais de uma matriz  $A$ , estudados nas últimas aulas. De maneira direta, podemos averiguar que as seguintes duplas de espaços são ortogonais:

- Espaço Coluna  $Im(A)$  e Espaço Nulo da Transposta  $N(A^t)$
- Espaço Linha  $Im(A^t)$  e Núcleo  $N(A)$

#### 4.3.2 Complemento Ortogonal

**DEF:** Seja  $V$  um subespaço de  $R^n$ . O conjunto

$$W = \{w \in R^n : \langle v, w \rangle = 0, \forall v \in V\}$$

forma um subespaço de  $R^n$ , chamado de *complemento ortogonal* de  $V$  e denotado por  $V^\perp$

Propriedades Importantes:

1.  $\dim(V) + \dim(V^\perp) = n$ , sendo  $n$  a dimensão de  $R^n$
2.  $V \cap V^\perp = \emptyset$
3.  $V \cup V^\perp = R^n$

### 4.4 Conclusão

Neste capítulo foram apresentados conceitos de ortogonalidade, produto interno, norma e complementos ortogonais.

## 5 Projeções Ortogonais

### 5.1 Conceitos importantes

Embora seja provável que estes conceitos já sejam bem conhecidos, vamos apenas relembrar o que são produto interno e sua relação com ortogonalidade, a Desigualdade de Cauchy-Schwarz e a Desigualdade Triangular.

**Def:** o produto interno entre dois vetores  $u$  e  $v$  pode ser definido como:

$$\langle u, v \rangle = \sum_{k=1}^n x_k y_k = x_1 y_1 + x_2 y_2 + \dots + x_n y_n$$

Uma outra maneira de definir o mesmo produto interno é:

$$\langle u, v \rangle = \|u\| \cdot \|v\| \cdot \cos(\theta)$$

onde  $\|u\|$  é a norma do vetor  $u$  e  $\theta$  é o ângulo entre os vetores  $u$  e  $v$ .

A partir desta definição, podemos derivar que dois vetores são ortogonais se e somente se o produto interno entre eles é zero. Isso é justificado por  $\cos(90) = 0$ .

**Def:** Desigualdade de Cauchy-Schwarz em  $R^n$

$$\|u \cdot v\| \leq \|u\| \cdot \|v\|$$

**Def:** Desigualdade Triangular

$$\|u + v\| \leq \|u\| + \|v\|$$

## 5.2 Projeção ortogonal sobre um vetor

Imagine que queiramos projetar um vetor  $v$  sobre um vetor  $u$ . Note que o vetor  $w$  da figura 1 abaixo é, justamente, o resultado dessa projeção.




Figura 1: Projeção ortogonal de  $v$  em  $u$

Precisamos de duas premissas, as quais são facilmente observadas na figura acima:

$$w = \alpha \cdot u$$

$$\langle u, v - w \rangle = 0$$

A maneira de encontrar, explicitamente,  $w$  em função de  $u$  e  $v$ , com base nessas premissas, está descrita abaixo:

$$\langle u, v - w \rangle = 0$$

$$\langle u, v - \alpha u \rangle = 0$$

$$u \cdot v - \alpha \cdot u \cdot u = 0$$

$$\alpha \cdot u \cdot u = u \cdot v$$

$$\alpha = \frac{u \cdot v}{u \cdot u}$$

Sendo assim, temos:

$$w = \left( \frac{u \cdot v}{u \cdot u} \right) \cdot u$$

Note que o resultado dos produtos internos entre parênteses é um número, garantindo que  $w$  e  $u$  são paralelos.

### 5.2.1 Matriz de Projeção sobre o vetor $u$

Podemos encapsular a projeção ortogonal sobre um vetor  $u$  em uma matriz  $P$ , da seguinte forma:

$$\begin{aligned} w &= \left( \frac{u \cdot v}{u \cdot u} \right) \cdot u \\ &= \left( \frac{u^T v}{u^T u} \right) \cdot u \\ &= u \left( \frac{u^T v}{u^T u} \right) \\ &= \left( \frac{uu^T}{u^T u} \right) v \\ &= P \cdot v \end{aligned}$$

### 5.2.2 Exemplo:

Calcule a matriz de projeção sobre o vetor  $u = (1, -1, 1)$

$$\begin{aligned} P &= \left( \frac{uu^T}{u^T u} \right) \\ P &= \frac{1}{3} \begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix} (1 \quad -1 \quad 1) \\ P &= \frac{1}{3} \begin{pmatrix} 1 & -1 & 1 \\ -1 & 1 & -1 \\ 1 & -1 & 1 \end{pmatrix} \end{aligned}$$

### 5.2.3 Propriedades:

A matriz  $P$  definida possui as seguintes propriedades:


1.  $P$  é simétrica
2.  $P^2 = P$
3.  $\text{Posto}(P)=1$

## 5.3 Projeção Ortogonal sobre um subespaço qualquer

Considere as matriz  $A$  e o vetor  $b$  definidos abaixo. Além disso, seja  $w$  a projeção ortogonal de  $b$  sobre o espaço coluna de  $A$ .

$$A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{pmatrix}, b = \begin{pmatrix} b_{11} \\ b_{21} \\ b_{31} \end{pmatrix}$$



Figura 2: projeção ortogonal sobre imagem de  $A$ 

Note que:

1. o vetor  $b - w$  é ortogonal ao espaço coluna de  $A$
2. o vetor  $b - A\bar{x}$  é ortogonal ao espaço coluna de  $A$ , sendo  $w = A\bar{x}$ .
3. Logo,  $b - A\bar{x} \in \text{Núcleo da Transposta de } A$
4.  $A^T(b - A\bar{x}) = 0$
5.  $A^T b = A^T A\bar{x} \rightarrow \text{Equação Normal}$

**Obs:** se as colunas de  $A$  são  $LI$ , então  $A^T A$  é inversível.

Com isso, chegamos na matriz de projeção sobre o espaço coluna de  $A$ :

$$P = A (A^T A)^{-1} A^T$$

## 5.4 Conclusão

Neste capítulo foram apresentados conceitos projeções ortogonais sobre u vetor e sobre um subespaço vetorial qualquer.

# 6 Mínimos Quadrados

## 6.1 Motivação

Como já sabemos, estamos quase sempre interessados em resolver sistemas do tipo  $Ax = b$ . No entanto, há casos em que a solução deste sistema é impossível. Por exemplo, se o nosso sistema linear for um sistema linear de equações incompatíveis.

**Def:** Sistemas lineares incompatíveis são sistemas de  $m$  equações e  $n$  incógnitas onde  $m > n$ . Outra maneira de olhar para essa definição é pensar em matrizes  $A_{m \times n}$ , as quais possuem  $m$  linhas (equações) e  $n$  colunas (incógnitas). Sabemos que sistemas desse tipo não possuem solução.

O que fazer, pode ser feito, além de abandonar o problema e ir dormir em paz, é procurar uma solução aproximada de tal modo que o **erro** desta solução seja o menor possível.

**Def:** o erro de uma solução aproximada de um sistema  $Ax = b$ , é definido como:

$$\|Ax - b\|, \text{ onde } b \text{ é a solução real e } Ax \text{ é a solução aproximada.}$$

Perceba que, para casos em que podemos encontrar a solução real do sistema, esse erro é zero, uma vez que  $Ax = b$ , logo  $\|Ax - b\| = 0$ .

Mas e quando não é possível encontrar a solução?

x	y
-1	1
1	1
2	3

## 6.2 Relembrando Projeções Ortogonais

Lembre-se do capítulo passado sobre projeções ortogonais e acrescente um detalhe.




Figura 3: projeção ortogonal sobre imagem de  $A$

No âmbito de minimização de erro, podemos pensar que queremos a menor distância entre a solução real e a aproximada. Sendo assim, a *Projeção Ortogonal* aprendida de mostra muito adequada para esse problema de aproximação.

A própria equação normal  $A^T A \bar{x} = A^T b$  relaciona esses valores. Tenha isso em mente.

## 6.3 Mínimos Quadrados

Uma vez que o sistema linear  $Ax = b$  é incompatível, sabemos que  $b \notin Col(A)$ . Sendo assim, já sabemos que a melhor solução, a que minimiza o erro, será a solução  $\bar{x}$  tal que:

$$A\bar{x} = Proj_{Col(A)} b$$

Como vimos na aula anterior, podemos definir uma matriz  $P$  de projeção sobre o espaço coluna de  $A$ . Utilizando essa informação, chegamos no seguinte sistema:

$$A\bar{x} = Pb$$

Este sistema, agora, é compatível e possui uma solução.

Vejamos, por fim, um exemplo prático de como calcular a melhor reta para um dado conjunto de pontos (regressão linear).

### 6.3.1 Exemplo:

Encontre a reta que melhor interpola os seguintes pontos:

Dados esses pontos, podemos montar o seguinte sistema linear  $Ax = y$ :

$$\begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \end{pmatrix} \cdot \begin{pmatrix} b \\ a \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix}$$

$$\begin{pmatrix} 1 & -1 \\ 1 & 1 \\ 1 & 2 \end{pmatrix} \cdot \begin{pmatrix} b \\ a \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 3 \end{pmatrix}$$

Rescrevemos como da seguinte maneira:

$$\begin{aligned} Ax &= y \\ A^T Ax &= A^T y \end{aligned}$$

Colocando valores:

$$\begin{pmatrix} 1 & 1 & 1 \\ -1 & 1 & 2 \end{pmatrix} \begin{pmatrix} 1 & -1 \\ 1 & 2 \end{pmatrix} \cdot \begin{pmatrix} b \\ a \end{pmatrix} = \begin{pmatrix} 1 & 1 & 1 \\ -1 & 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 3 \end{pmatrix}$$

Resolvendo o sistema, encontramos  $a = \frac{4}{7}$  e  $b = \frac{9}{7}$ .

Logo, a reta desejada é:  $r(x) = \frac{4}{7} \cdot x + \frac{9}{7}$

## 6.4 Conclusão

Neste capítulo foi lembrado o conceito de projeções ortogonais sobre um subespaço vetorial qualquer e apresentado o algoritmo de Mínimos Quadrados.

# 7 Matrizes Ortogonais, Ortogonalização de Gram-Schmidt e Fatoração QR

## 7.1 Matrizes Ortogonais

Para definir uma matriz ortogonal, precisamos lembrar o que é um conjunto de vetores, ou uma base, se quisermos, ortonormal.

**Def:** uma base  $\beta$  de vetores de  $R^n$  é dita ortonormal se todos os vetores que a formam possuem, simultaneamente, norma 1 e são ortogonais entre si.

Com essa definição, podemos definir tranquilamente uma Matriz Ortogonal.

**Def:** Uma Matriz Ortogonal  $A$  é uma matriz cujas colunas formam uma base ortonormal.

Algumas propriedades das matrizes ortogonais são importantes para nosso curso.

### 7.1.1 Propriedades

(1) Toda matriz ortogonal  $Q$  satisfaz  $Q^T Q = I$ . Dessa propriedade, nota-se que  $Q^T = Q^{-1}$

*Prova:* note que uma multiplicação matricial é, de certo modo, um produto interno entre as colunas e linhas das matrizes. Sendo assim, como as colunas de  $Q$  são ortonormais,  $\langle v_i, v_j^T \rangle = 0 \forall i \neq j$ , sendo  $v_i$  os vetores da coluna de  $Q$  e  $v_j$  os vetores linhas de  $Q^T$ . A partir disso mostramos que  $Q^T Q = I$ .

(2) A multiplicação de uma matriz ortogonal por um vetor preserva o comprimento do vetor  $\rightarrow \|Qx\| = \|x\|$ .

$$\text{Dem: } \|Qx\|^2 = \langle Qx, Qx \rangle = (Qx)^T Qx = x^T Q^T Qx = x^T x = \|x\|^2$$

(3)) O ângulo entre vetores se preserva por matriz ortogonal.

$$\text{Dem: } \cos\theta = \frac{\langle Qu, Qv \rangle}{\|Qu\| \|Qv\|} = \frac{uQ^T Qv}{\|u\| \|v\|} = \frac{u^T v}{\|u\| \|v\|}$$

## 7.2 Ortogonalização de Grand Schmidt

O processo de ortogonalização de Grand-Schmidt consiste em uma estratégia para, a partir de uma base qualquer  $\{a_1, \dots, a_n\}$ , obter uma base ortonormal  $\{q_1, \dots, q_n\}$  para o espaço gerado pela base  $a$ . Temos a seguinte construção:

$$\begin{aligned} a'_1 &= a_1 \rightarrow q_1 = \frac{a'_1}{\|a'_1\|} \\ a'_2 &= a_2 - (q_1^T a_2)q_1 \rightarrow q_2 = \frac{a'_2}{\|a'_2\|} \\ a'_3 &= a_3 - (q_1^T a_3)q_1 - (q_2^T a_3)q_2 \rightarrow q_3 = \frac{a'_3}{\|a'_3\|} \\ a'_n &= a_n - (q_1^T a_n)q_1 - \dots - (q_{n-1}^T a_n)q_{n-1} \rightarrow q_n = \frac{a'_n}{\|a'_n\|} \end{aligned}$$

## 7.3 Fatoração QR

O processo de ortogonalização de Grand Schmidt nos entrega uma fatoração conhecida como **fatoração**  $A = QR$ . Não é difícil imaginar que a matriz  $Q$  desta fatoração será a matriz cujas colunas são a base  $\{q_1, \dots, q_n\}$  obtida no processo de ortogonalização e  $A$  é a matriz cujas colunas são a base  $\{a_1, \dots, a_n\}$ .

Antes de definirmos a matriz  $R$ , lembremos:

Se  $\{q_1, \dots, q_n\}$  é base ortonormal de  $R^N$  e  $b$  pertence a esse espaço gerado, então...

$$b = c_1 q_1 + c_2 q_2 + \dots + c_n q_n$$

onde

$$c_1 = q_1^T b, c_2 = q_2^T b, \dots, c_n = q_n^T b$$

Vejamos como construir a matriz  $R$  para o caso de uma base do  $R^3$ . Esse procedimento é facilmente generalizado para  $R^N$ .

**Exemplo:** Seja  $\{a, b, c\}$  base para o  $R^3$  e  $\{q_1, q_2, q_3\}$  base ortonormal obtida via ortogonalização de Grand Schmidt a partir da base  $\{a, b, c\}$ .

Temos que:

$$a = (q_1^T a)q_1 + (q_2^T a)q_2 + (q_3^T a)q_3 = (q_1^T a)q_1$$

A primeira coluna de  $R$  será, então,  $(q_1^T a, 0, 0)^T$

$$b = (q_1^T b)q_1 + (q_2^T b)q_2 + (q_3^T b)q_3 = (q_1^T b)q_1 + (q_2^T b)q_2$$

A segunda coluna de  $R$  será, então,  $(q_1^T a, q_2^T b, 0)^T$

$$a = (q_1^T c)q_1 + (q_2^T c)q_2 + (q_3^T c)q_3$$

A terceira coluna de  $R$  será, então,  $(q_1^T a, q_2^T b, q_3^T c)^T$

$$\text{Logo, } R = \begin{pmatrix} q_1^T a & q_1^T a & q_1^T a \\ 0 & q_2^T b & q_2^T b \\ 0 & 0 & q_3^T c \end{pmatrix}$$

## 7.4 Conclusão

Neste capítulo apresentados os conceitos de Matriz Ortogonal, Processo de Ortogonalização de Grand-Schmidt e Fatoração  $A = QR$ .